

高山生態系におけるデジタルタイムラプスカメラを用いた植生図の自動描画

プレプリント

岡本 亮太郎 *

筑波大学大学院生物学研究

科博士後期課程

305-8577 茨城県つくば市天王台1丁目1番1号

okamoto.ryotaro.su@alumni.tsukuba.ac.jp

小熊裕之

生物多様性部門

国立環境研究所 〒305-8506 茨城県つくば市小
野川16-2

oguma@nies.go.jp

井手礼子

地球システム部門

国立環境研究所 〒305-8506 茨城県つくば市小
野川16-2

ide.reiko@nies.go.jp

2022年7月28日

概要

ここにアブストラクトのテキストを入力してください。

Keywords 高山生態学 - 深層学習 - 生態系モニタリング

1 はじめに

気候変動が陸域生態系に及ぼす影響は、特に高山地帯で顕著である ([1])。高山植生は、低温や長い積雪期間といった厳しい条件に依存している。そのため、高山地帯には、極限環境に適応した希少種や固有種が生息している。近年の地球規模の気候変動（気温の上昇や積雪期間の短縮など）が、高山域への外来種の侵入を加速させていることが、いくつかの研究で報告されています ([2]参照)。日本では、無雪期の延長を背景に、ヒメシャラ (*Sasa kurilensis*) が高山の雪原に侵入している ([3])。また、気候変動は在来種の生育やフェノロジーに影響を与えている。例えば、日本の高山地帯で優占種であるハイマツの成長は、気温や融雪量などの気候条件の影響を受けている ([4])。効果的な保全計画を立てるには、このような変化を検知するために、植生分布の常時モニタリングが必要である。また、気候変動が高山植生に与える影響は、種やマイクロハビタットによって異なるため ([5])、空間的に高分解能で広い範囲のモニタリングが必要である。

これまでの研究は、主に現地での観測に頼ってきたが、高山地帯は交通の便が悪く、天候も厳しいため、広範囲をカバーすることは難しい。衛星、航空機、無人航空機 (UAV) によるリモートセンシングがその代替手段と思われる。しかし、高山地帯の衛星画像は雲に覆われていることが多く、植物群落のスケールで植生変化を観察するには空間分解能が十分ではありません。航空機による画像は高解像度のデータを得ることができるが、頻繁にモニタリングを行うにはコストがネックとなる。UAVによる手法は生態系モニタリングのための費用対効果の高いツールとなっていますが ([6])、高山地域でのUAVの運用は強風と厳しい地形により困難なものとなっています。

一方、森林 ([7])、草原 ([8])、高山草原 ([9]) では、地上に設置した自動デジタルタイムラプスカメラで緑葉のフェノロジーをモニタリングすることも行われている。とは異なり

*<https://github.com/0kam>

衛星画像は、雲や大気の影響を受けずに撮影することができます。また、高解像度（サブメータスケール）かつ高頻度（毎日または毎時）の画像を安価に入手することができます。これらの研究では、画像中にいくつかの関心領域（ROI）を設定し、フェノロジー指標（例えば、過剰緑度[10]）を算出している。しかし、このような画像を植生分布のモニタリングに活用した研究はほとんどない。これは、このような繰り返し撮影を植生分布のモニタリングに適用するには、2つの技術的な課題があるためと思われる。

第一に、衛星のマルチスペクトルセンサーと異なり、通常のデジタルカメラは3つのバンド（赤、緑、青）しか取得できないため、植生を分類することが困難である。第二に、デジタルタイムラプスカメラは地上に設置されるため、これらの画像を地理空間データ（オルソ画像など）に変換することが困難であることです。つまり、このような画像から植生を分類しても、地理データとして定量的に計測・解析することができないのです。保全計画に活用するためには、地上画像を地理データとして扱うことが不可欠なのです。

本研究では、この2つの課題を解決することで、デジタルタイムラプスカメラによる植生図の自動描画手法を提案する。第一の課題は、タイムラプス画像を用いて植生を分類することで解決した。秋の葉のフェノロジーは種によって異なるため、その情報を活用した。このようなフェノロジーの情報が植生分類に有効であることを示す。また、2つ目の課題に対しては、地上写真を地理データに変換する新しい手法を開発した。最後に、提案手法によって描かれた植生図の例を示す。我々は、安価で高性能なデジタルタイムラプスカメラを、高山生態系のモニタリングや保全に活用することを目指している。

2 材料と方法

2.1 デジタルタイムラプスカメラ画像

国立環境研究所が所有する繰り返し撮影データを使用しました。すべての画像は国立環境研究所のウェブページ (<https://db.cger.nies.go.jp/gem/ja/mountain/station.html?id=2>) で公開されている。国立環境研究所は、2010年に北アルプス立山（標高3015m）の山麓にある室堂山荘（標高約2350m、森林限界以上）にデジタルタイムラプスカメラ（EOS 5D MK2、キヤノン株式会社、21Mピクセル）を設置し1時間に1枚の写真を撮影しています。撮影時間は、午前6時から午後7時まで、1時間に1枚。撮影範囲は、標高約2350mから3015mまでの立山を含む。この地域は、岩石、崖、カール、モレーンなどの地形のため、モザイク状の複雑な植生構造になっています。4月から11月にかけて、常緑樹（*Pinus pumila* など）や落葉樹（*Sorbus* sp.、*Betula ermanii*）の矮小樹、矮小竹（*Sasa kurilensis* など）、高山低木や草本（*Geum pentapetalum*、*Nephrophyllidium crista-galli* など）の雪解けや季節の表情を撮影してきた。本研究では、2015年の夏から秋にかけての画像を用いて、葉色の時間的パターンで植生を分類した。

2.2 前処理

2.2.1 画像を選択する

まず、植生分類に適した画像を選定した。2015年の晩夏から晩秋にかけての好天の7日間（8/25, 9/5, 9/12, 9/20, 9/26, 10/3, 10/10）を選びました。この時期の画像は、紅葉の色づきのパターンから植生を分離できるため、この時期の画像を使用しました。

2.2.2 画像間の自動アライメント

画像は若干のずれがあるため、処理前に位置合わせを行った。プログラミング言語Python3と画像処理ライブラリOpenCV4 (<https://opencv.org/>) を用いてプログラムを実装しました。まず、2015年の画像1枚をアライメント対象として設定しました。次に、AKAZE局所特徴抽出器 ([11]) とK-nearest neighbor matcherを用いて、対象となる画像と他の画像の間で一致するキーポイントを自動的に検出した。次に、OpenCVの "findHomography" 関数を用いて、マッチング点の各ペア間の距離を最小化するホモグラフィ行列を探索し、適用した。推定したホモグラフィ行列を適用したところ、画像を正確に位置合わせすることができました（マッチング点の二乗平均平方根誤差（rmse）が0.654ピクセル）。最後に、空やカメラに近すぎる領域など、以下の手順で無視すべき画像領域を定義するための入力マスクを用意しました。

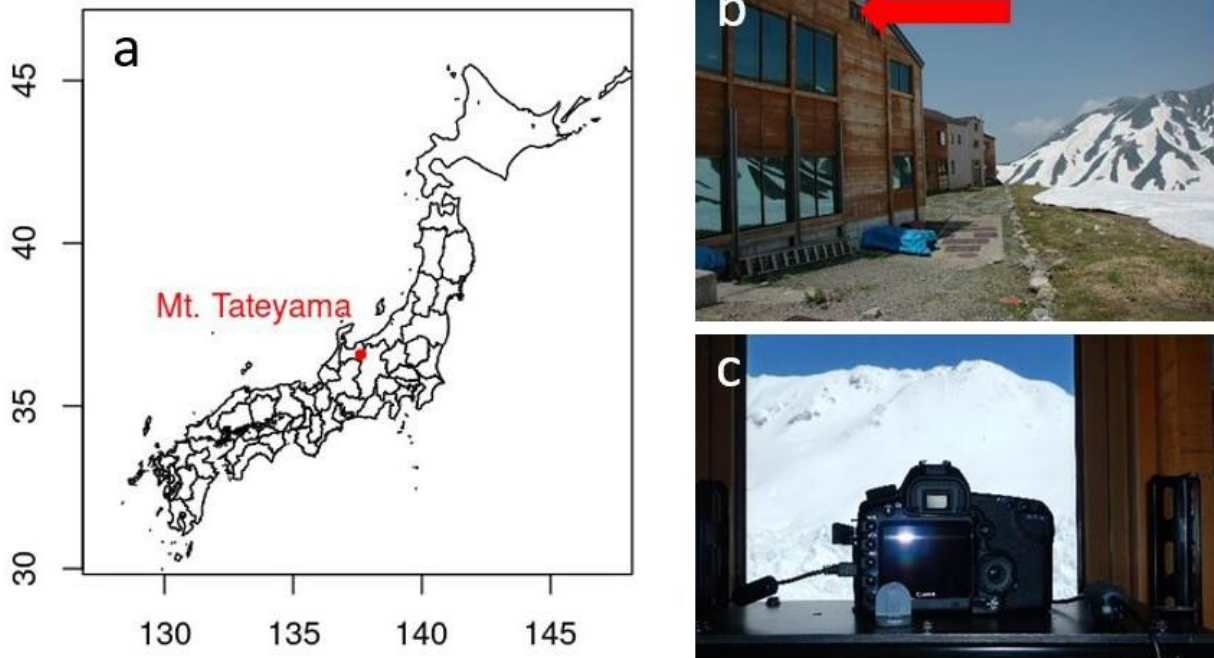


図1：調査地。(a)立山の位置。(b) 室堂山荘のカメラ設置場所。(c) カメラ（EOS 5D MK2、キヤノン株式会社）。

2.3 自動植生分類

画像の位置合わせに成功したため、画像を重ね、各画素の画素値（赤、緑、青、2）の時系列を抽出することができます。このような画素の時系列は、葉の色の時間的なパターンを反映しています。落葉樹は種によって秋のフェノロジーが大きく異なるため、研究者はその情報を衛星画像を用いた植生分類に利用しています（例えば[12], [13], [14]）。しかし、地上からの繰り返し撮影画像にこの手法を適用した研究はない。本研究では、サポートベクターマシン（SVM）とリカレントニューラルネットワーク（RNN）に基づく植生分類手法を実装しました。また、画素の時系列を用いることが分類性能に与える影響を検証した。

2.3.1 モデル・アーキテクチャ

画素の時系列を植生カテゴリに分類するために、SVMとRNNという二つの教師ありモデルを用意した。SVMは、リモートセンシングで最も有名な機械学習モデルの一つで、多時刻衛星画像による植生分類（[12]）など、多くの応用がある（[15]）。RNNは、時間的または連続的なデータのダイナミクスを認識するニューラルネットワークである。また、研究者は、多時間の衛星画像を用いた土地被覆分類などのリモートセンシングタスクにRNNを利用している（[?] , [16]）。RNNの多くのバリエーションの中で、我々は最もよく知られたRNNアーキテクチャの一つであるLong Short Time Memory (LSTM、[17]) を使用しました。また、多時期の画像を用いることで分類性能が向上するかどうかを検証するために、SVM分類器を用いて1枚1枚の画像の画素を個別に分類しました。

2.3.2 データセットの準備

植生クラスは7つ設定した。植生クラスは、ヒメコマツ（*Pinus pumila*）、ヒメシャラ（*Sasa kurilensis*）、ローワン（*Sorbus sambucifolia*, *Sorbus matsumurana*）、白樺（*Betula ermanii*）、ハンノキ（*Alnus viridis* subsp. *maximowiczii*）、その他の植生（高山低木や草本など）および植生なし、の7種類としました。オープンソースの画像アノテーションソフトウェア（Semantic Segmentation Editor, Hitachi, <https://github.com/Hitachi-Automotive-And-Industry-Lab/semantic-segmentation-editor>）を用いて、専門家が各クラス用の教師データセットを作成した。そして、2016年の夏から秋にかけて撮影した望遠写真一式を用いて、教師データセットの検証を行いました。




図2：タイムラプスカメラから取得した画素時系列。写真上の各ピクセルの値（赤、緑、青）の時系列を得ることができる。このような画素の時系列は、植生の秋のフェノロジーを反映している。

2.3.3 実装とモデルトレーニング

Python3言語、SVM分類器にはThunderSVMライブラリ (<https://github.com/Xtra-Computing/thundersvm>)、深層神経回路ライブラリPyTorchを用いて実装しました (<https.org>)。RNN分類器には、[//pytorch.org/](https://pytorch.org/)) を使用します。すべてのソースコードはGitHubで公開されています (<https://github.com/0kam/xxxx>)。

2.4 自動ジオレクティフィケーション

そこで、地上の風景画像をGISで利用可能な地理データに変換する新しい方法を開発しました。この処理はジオレクティフィケーションと呼ばれています。これまで、地上画像のジオレクティフィケーションは困難な作業であり、そのために地上画像に潜在する豊富な情報が十分に活用されているとは言えませんでした。ジオレクティフィケーションとは、画像をデジタルサーフェスモデル (DSM) 上に配置し、画像の各ピクセルに地理的な座標を付与することです。これを行うには、カメラをモデル化する必要があります。カメラは、3次元の地理座標（例えば、UTM (Universal Transverse Mercator) 座標系におけるX、Y、高さ）を2次元の画像座標（画像内の各ピクセルの位置）に変換する関数として考えられます。この関数のパラメータ（カメラの位置、姿勢、FoVなど）を推定することで、DSMの各点が画像上でどのように表示されるかをシミュレーションすることができます。通常、ジオレクティフィケーションは3つのステップで行われます。

1. 画像内のGCP (Ground Control Point) を検索する。
2. GCPを用いたカメラのポーズや視野などのカメラパラメータの推定。
3. カメラパラメータを使用して画像にDSMを投影する。

近年、氷河研究 ([18]) や積雪研究 ([19]) において、地上写真を利用したジオレクティフィケーションの手法が開発されている。特に[19]は、山のシルエットをGCPとした半自動的な手法であり、特筆に価すると思われる。しかし、このシルエットを用いた方法は、投影精度に欠点がある。また、レンズの歪みも無視することになる。今回の対象地は植生が複雑に分布しており、カメラのレンズの歪みも大きいので、より精度の高い方法が必要だったのです。

2.5 カメラパラメータのモデリングと推定

前述したように、カメラは、取得した画像中の対象山の地理的座標を画像座標に変換する機能として考えた。この処理をGPU (Graphical Processing Unit) で高速化するために、OpenGLというフレームワークを用いて実装しました。OpenGLでは、この処理を3つの操作に分離することができる。

1. カメラの外部パラメータ (カメラの位置や角度など) を用いて、ワールド (地理) 座標をビュー座標 (カメラから見た座標) に変換すること。
2. レンズディストーションパラメータを使用してビュー座標を歪ませる。
3. カメラの固有パラメータ (カメラのFoVとアスペクト比) を用いて、ビュー座標をスクリーン (画像) 座標に変換する。

まず、絶対的な地理座標 (世界座標ともいう) を、カメラの位置と方向に対する相対座標であるビュー座標に変換した。このステップでは、地理座標に4×4のビュー行列 M_{view} (2.5)を適用した。ビュー行列は、カメラの位置と方向 (パン、チルト、ロール) を表しています。なお、地理座標系は直交座標系でなければならない (UTMなど)。

$$M_{view} = \begin{bmatrix} \cos \text{ロール} & -\sin \text{ロール} & 0 & 0 \\ \sin \text{ロール} & \cos \text{ロール} & 0 & 0 \\ 0 & 0 & \sin \text{チルト} & \cos \text{チルト} \\ 0 & 0 & \cos \text{チルト} & -\sin \text{チルト} \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix} \begin{bmatrix} \cos \text{パン} & 0 & \sin \text{パン} & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} \quad (1)$$

ここで、 pan , tilt , roll はカメラポーズのオイラー角、 x , y , z は地理座標系でのカメラ位置である。そして、DSM の地理座標 $[X_{geo} \ Y_{geo} \ Z_{geo} \ 1]$ を、ビュー行列 M_{view} を適用して、ビュー座標 $[X_{view} \ Y_{view} \ Z_{view} \ 1]$ に変換することができる (2.5)。OpenGLのビュー座標系において、 X_{view} , Y_{view} , Z_{view} はそれぞれ水平、垂直、奥行き位置を表す。

$$\begin{bmatrix} X_{view} \\ Y_{view} \\ Z_{view} \\ 1 \end{bmatrix} = M_{view} \begin{bmatrix} X_{geo} \\ Y_{geo} \\ Z_{geo} \\ 1 \end{bmatrix} \quad (2)$$

第二に、レンズの歪みをシミュレートするために、カメラ座標を歪ませた。レンズの歪みは、[20] と OpenCV の実装 (https://docs.opencv.org/4.x/d9/d0c/group_calib3d.html) に基づき、 X_{norm} と Z_{norm} は Y -正規化したビュー座標でモデル化した (2.5)。このモデルは、画像表面に投影したとき、画像の中心からの距離に応じて、点の位置を歪ませる。このモデルには、半径方向 ($k_1 \sim k_6$)、接線方向 (p_1 , p_2)、薄型プリズム ($s_1 \sim s_4$)、画素の縦横比 (a_1 , a_2) の歪みが含まれています。レンズ歪みのモデリングの詳細については、[20]を参照してください。

$$X_{norm} = \frac{X_{cam}}{r_{cam}} \quad (3)$$

$$Z_{norm} = \frac{Z_{cam}}{r_{cam}} \quad (4)$$

$$r^2 = X_{norm}^2 + Z_{norm}^2 \quad (5)$$

$$\begin{bmatrix} X_{dist_norm} \\ Y_{dist_norm} \\ Z_{dist_norm} \end{bmatrix} = \begin{bmatrix} X_{norm} \\ Y_{norm} \\ Z_{norm} \end{bmatrix} + \begin{bmatrix} k_1 + k_2 r^2 + k_3 r^4 + k_4 r^6 \\ k_5 + k_6 r^2 + k_7 r^4 + k_8 r^6 \\ k_9 + k_{10} r^2 + k_{11} r^4 + k_{12} r^6 \end{bmatrix} + \begin{bmatrix} p_1 X_{norm} Y_{norm} + p_2 (Y_{norm}^2 - X_{norm}^2) + s_1 r^2 + s_2 r^4 \\ p_3 (X_{norm}^2 - Y_{norm}^2) + p_4 X_{norm} Y_{norm} + s_3 r^2 + s_4 r^4 \\ 0 \end{bmatrix} \quad (6)$$

$$X_{dist} = X_{dist_norm} Y_{camera} \text{ とする。} \quad (7)$$

$Zdist = Zdist_norm Ycamera$ とする。 (8)
(9)

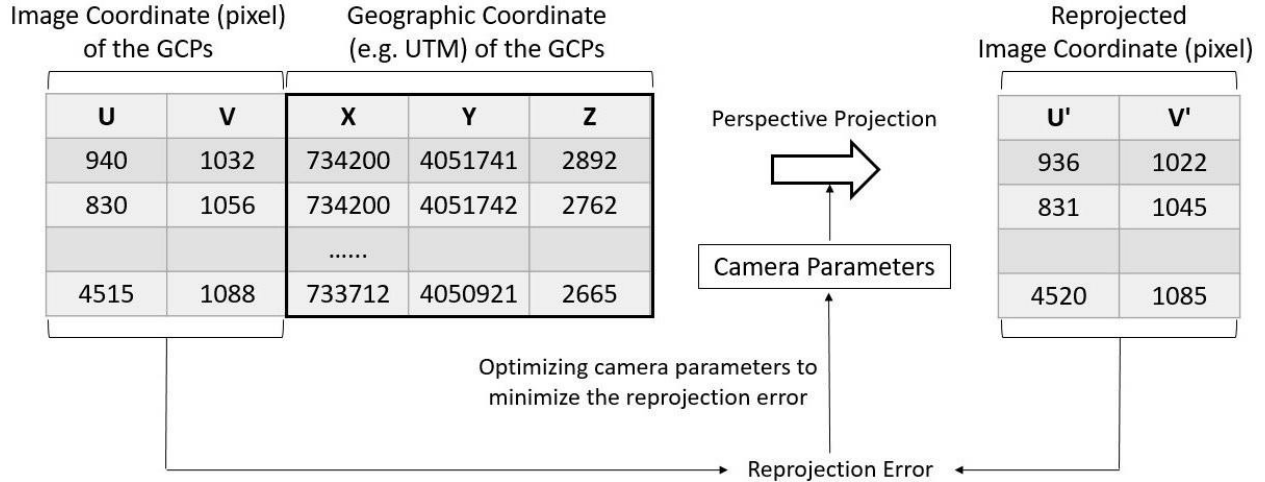


図3：カメラパラメータ最適化のワークフローGCPの再投影誤差を最小にすることで、カメラパラメータを推定しました。

次に、歪んだ視座標を透視投影により画像座標に変換する。透視投影では、近いものほど大きく描かれる。カメラの水平方向 (f_{ov_x}) と垂直方向 (f_{ov_z}) のFoVを表す 4×4 の投影行列 M_{proj} (2.5) を使用した。最後に、点の画像座標を X_{image}, Z_{image} (2.5) として得ることができる。

$$f_x = \frac{1}{\frac{1}{f_x} + \frac{1}{f_z} \frac{Z_{image}}{X_{image}}} \quad (10)$$

$$f_z = \frac{1}{\frac{1}{f_x} + \frac{1}{f_z} \frac{Z_{image}}{X_{image}}} \quad (11)$$

$$M_{proj} = \begin{bmatrix} f_x & 0 & 1 & 0 \\ 0 & f_z & 0 & 1 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & -1 & 0 \end{bmatrix} \quad (12)$$

$$\begin{matrix} X_{image} & X_{dist} \\ Z_{image} & Z_{dist} \\ M & \\ 1 & 1 \end{matrix} \quad (13)$$

これらの手順をGCPの地理座標に適用すると、カメラパラメータ（カメラの位置、姿勢、FoV、レンズの歪み）のセットで再投影画像座標を計算することができます。そして、GCPの実際の画像座標（3のU、V）から再投影画像座標（3のU'、V'）までの距離をメジャーで表示することができます。を最小化すること、カメラパラメータ（カメラ位置を除く）の最適化を行った。この距離を共分散行列適応進化戦略（CMA-ES, [21], 3）を用いて求めた。我々は、問題が複雑になりすぎるため、カメラの位置を推定します（例えば、遠くから撮影した望遠と近くから撮影した広角は似ています）。

2.6 画像マッチングによるGCPの取得

さらに、より広域の画像とDSMのマッチング点を得るために、オルソ画像化された航空機画像を追加で利用した。カメラモデルを航空機画像、DSM、カメラの初期パラメータに適用し、模擬風景画像4をレンダリングした。次に、AKAZE local feature matcher 4 を用いて、元画像とシミュレーション画像のマッチング点を求めた。このマッチングポイントは、地理座標（DSM）と画像座標（原画像）の両方を持つ

ため、これらの座標を使用した。

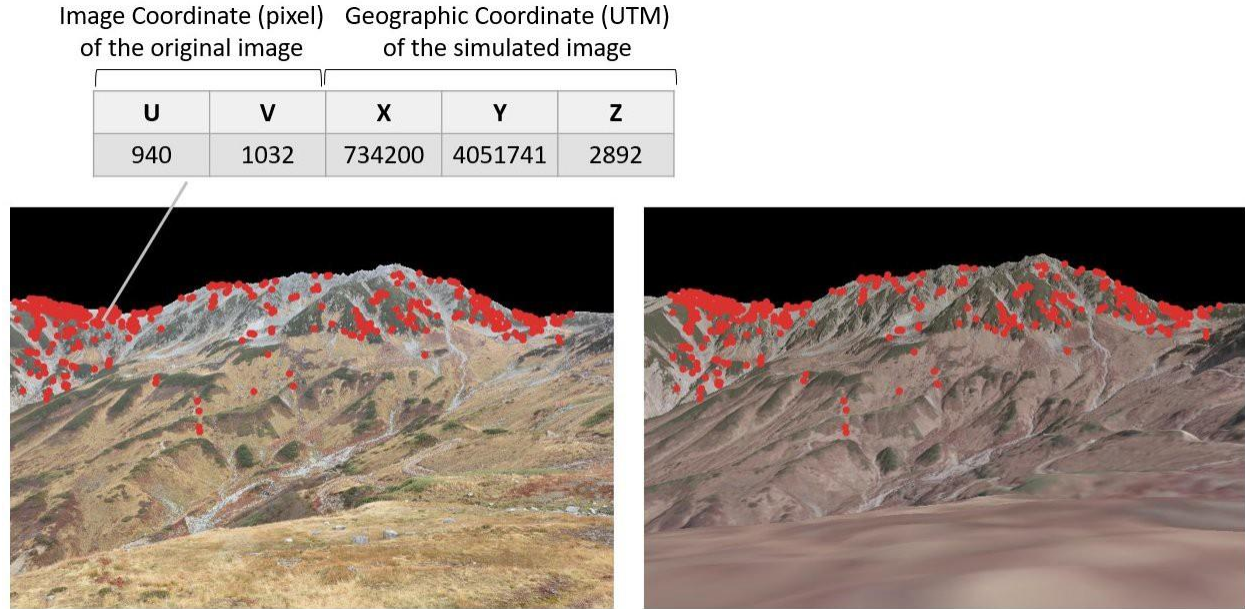


図4：オリジナル画像（左）とシミュレーション画像（右）。シミュレーション画像は、オルソフォト、DSM、および初期カメラパラメータを使用してレンダリングされた。赤い点は、AKAZEの局所特徴量マッチャーによって検出されたマッチング点である。この点をGCPとして使用した。

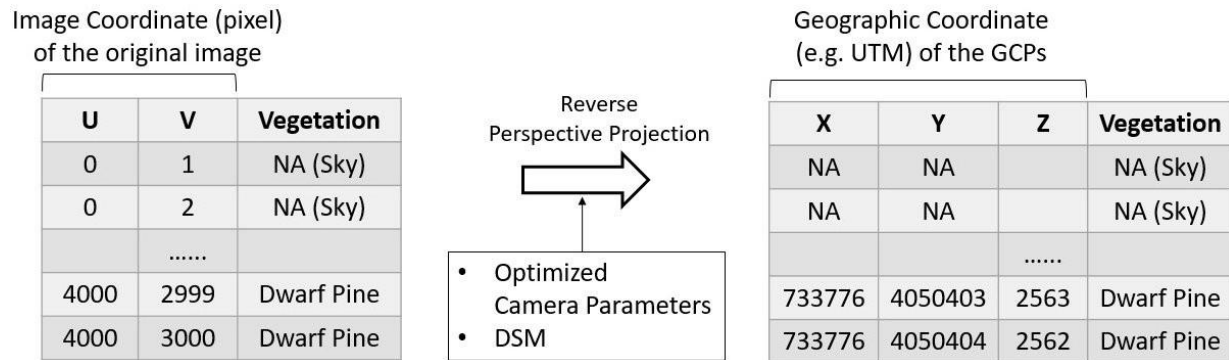


図5：当社のジオレクティフィケーションの手順。DSMと植生分類の結果に最適化したカメラパラメータを適用し、植生図を作成しました。

をGCPとする。この手順では、シミュレーション画像をレンダリングするために、カメラの正確な位置とカメラの初期パラメータが必要です。なお、空中写真のオルソ化精度はジオレクティフィケーションの精度に影響を与える可能性があります。

2.7 植生図のジオレクティフィケーション

最後に、最適化されたカメラパラメータを用いて、植生分類結果をジオレクティファイしました5。この時点で、元画像の各行が1画素を表す植生の点データ（5の右の表）を得ることができました。この点データをラスターデータに変換することで、各植生区分の面積を測定することができます。点データは1mの分解能でラスター化し、山の稜線上では最大2m程度の足跡があるため、2mまでの穴を補間した。これらの手順は、R言語 [22], starsパッケージ [23], terraパッケージ [24] を用いて実装しました。ソースコードは <https://github.com/0kam/xxx/xxx> を参照。

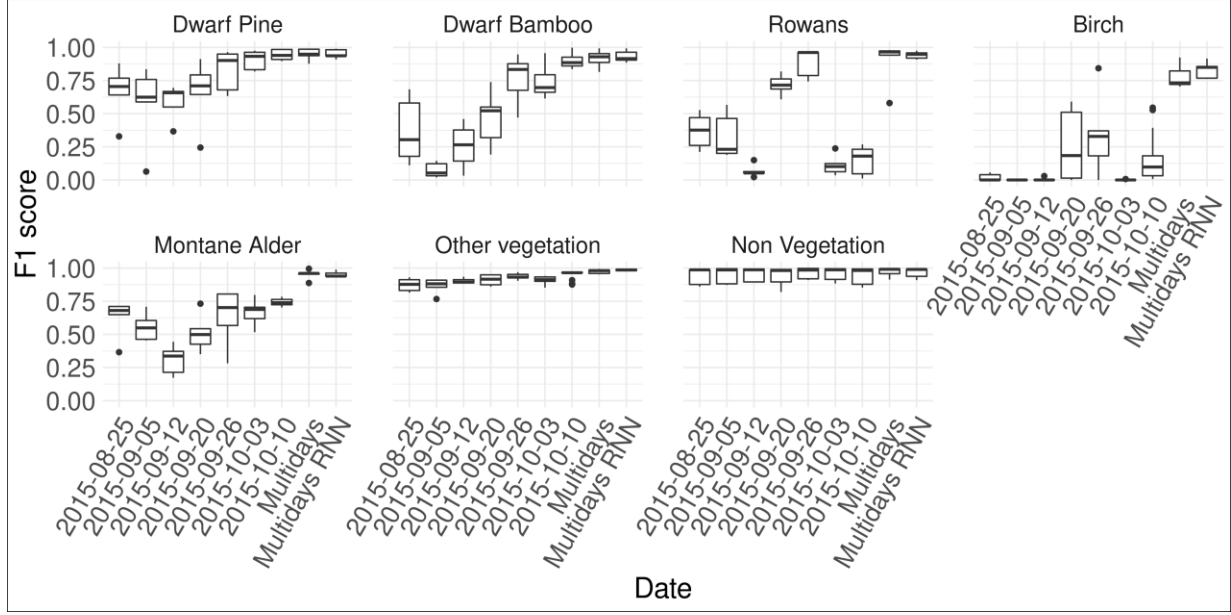


図 6: 植生分類の F1 スコア。F1スコアは植生クラスごとに算出した。各枠は5重クロスバリデーションの結果である。SVM分類器では単一画像（撮影日と表示）、SVM分類器（Multidaysと表示）、RNN分類器（Multidays RNNと表示）では全画像を用いて植生分類を行いました。

2.8 実装とデータセット

このアルゴリズムをPython3で実装し、オープンソースのパッケージとしてGitHub (<https://github.com/0kam/alproj>)で公開しました。手持ちのデータで試すことができる。また、空中写真のオルソ化処理に使用した1m解像度のデジタルサーフェスモデルも使用しました。

3 結果

3.1 植生分類精度

植生分類器の性能は、5重のクロスバリデーションにより評価した。各フォールドは植生カテゴリで層別した。F1スコアは、機械学習評価における標準的な指標である (3.1)。

$$\text{精度} = \frac{TP}{TP + FP} \quad (14)$$

$$\text{リコール} = \frac{TP}{TP + FN} \quad (15)$$

$$F_1 = \frac{2 \cdot \text{精度} \cdot \text{回収率}}{\text{精度} + \text{回収率}} \quad (16)$$

$$(17)$$

6 は、5 回クロスバリデーションの結果である。単一画像の分類（撮影日表示）に着目すると、分類に最適な日がクラスごとに異なっていることがわかる。例えば、9月26日はナナカマドの判別に最も適していましたが、10月10日はヒメコマツとヒメシャラの判別に適していました。なお、ナナカマドの紅葉は9月26日が最高で、ヒメオオとハイマツ以外の植生は10月10日に吹き飛んでいます。白樺とヤマハンノキは1枚の画像では正確に分類できません。

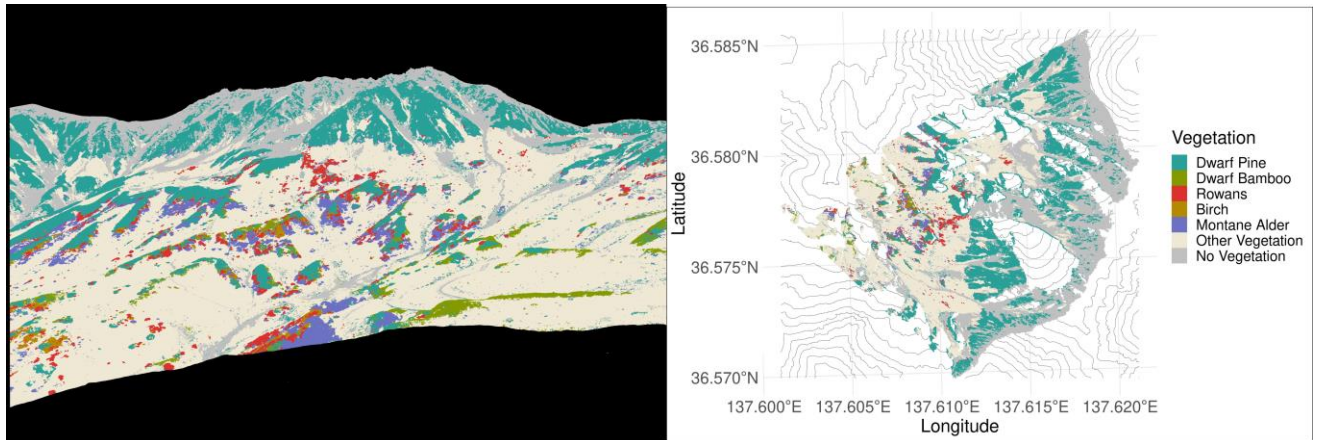


図7：左RNNモデルによる植生分類結果。マスクされた領域、すなわち空とカメラに近すぎる領域は黒で表示されている。生成された植生図。背景は等高線。

一方、全ての画像を用いた場合(SVM分類器を表す「Multidays」、RNN分類器を表す「Multidays RNN」)は、全てのクラスで高いF1スコアを得ることができました。また、RNN分類器はSVM分類器よりも優れています(マクロ平均F1スコアで0.937と0.918)。7(左)は、RNN分類器の生成物を示しています。植物群落のスケールでハイマツとハイマツタケの分布を観察することができる。

3.2 ジオレクチフィケーション精度

そこで、本手法の精度を検証するとともに、画像マッチングによるGCP取得と、レンズ歪みのモデル化という2つの特徴による効果を評価した。模擬写真とオリジナル写真から83点のマッチングポイントを手動で検索し、テストGCPとして扱いました。このGCPはジオレクチフィケーション処理に使用されないGCPです。さらに、提案手法の性能を検証するために、2つの比較手法を用意しました。1つ目は、先行研究([19])で用いられているシルエットベースのマッチング手法(以下、シルエットと呼ぶ)である。もう一つは、レンズ歪みモデルを用いない(以下、歪みなしと呼ぶ)提案手法である。これら3つの方法を用いて、テスト用GCPの投影誤差を評価した。提案手法は正確な投影(二乗平均平方根誤差として3.45 m)を達成したが、他の2つの手法はそうではなかった(シルエットで16.1 m, ディストーション無しで23.6 m)。シルエット法では、レンズの歪みパラメータを推定した。8に提案手法の投影誤差とテストGCPの撮影点からの距離の関係を示す。特に、撮影点に近いGCPで投影誤差が大きくなっていることがわかる。なお、投影誤差の値は、オルソフォトとDSMのジオレクチフィケーション誤差を無視して測定したものである。

7(右)は作成された植生図である。尾根がカメラの視野を遮っているため、植生図には欠損部分があります。

4 ディスカッション

我々は、タイムラプス画像をわずかなコストでジオリファレンス付き植生マップに変換する完全自動化手順を提案した。この課題は、1.デジタルカメラで撮影された通常の画像では植生分類が難しい、2.地上画像ではジオレクチフィケーションが困難である、というものであった。我々は、1.紅葉の時間情報を植生分類に利用すること、2.高精度な画像地理補正を行うための新しい手法を開発することで、これらの問題を解決しました。提案手法は、植生分類の平均F1スコアで0.937、地理補正の平均投影誤差で3.4mと、植物群落単位での植生分布のモニタリングに利用可能な性能を達成した。

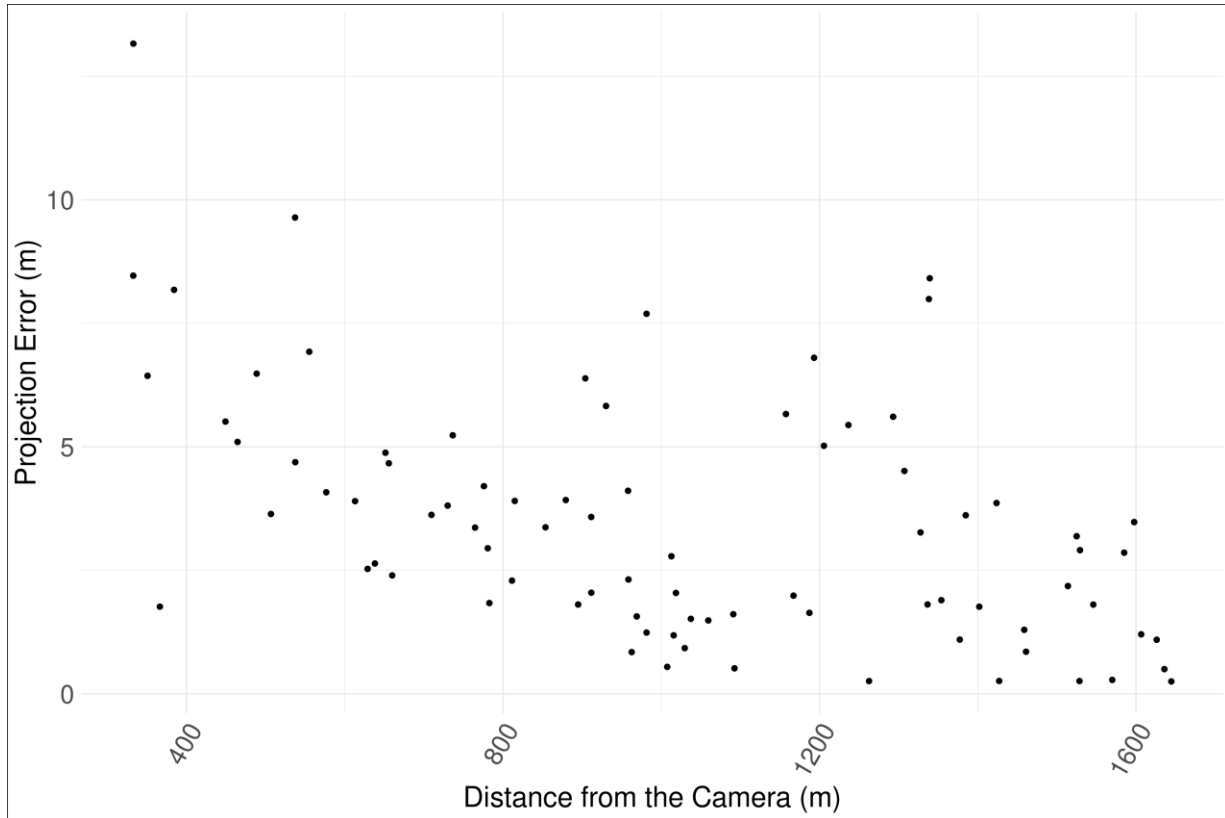


図8：RNNモデルによる植生分類結果。マスクされた領域、すなわち、空とカメラに近すぎる領域は黒で表示されている。カメラは植生図の左側の頂点に配置した。

4.1 植生分類に時系列画像を使用することの利点

デジタルカメラの欠点は、赤・青・緑の3バンドしかないことです。この情報不足を補うために、タイムラプスカメラが持つ豊富な時間情報を利用しました。植物の多くは紅葉などの特徴的なフェノロジーを持ち、観察に適した季節は種によって異なる。(6)の結果は、植生クラスごとに写真で識別するのに適した時期があることを示しています。したがって、複数の植生クラスを分類するためには、長期的（数ヶ月単位など）かつ頻繁（毎日など）にモニタリングを行う必要があり、デジタルタイムラプスカメラが適している。また、多時期の画像を組み合わせることで、特にBirchとMontane Alderで分類精度が向上しました(6)。単一画像による分類ではF1スコアが低かったのですが（Montane Alderで0.750、Birchで0.345）、多時期の画像を用いることで大幅に向上しました（SVM分類器では0.951、0.781）。この結果は、これらの植生を識別するためには、多時間の情報が必要であることを示唆しています。この結果は、紅葉時期の地域間不均質性が原因である可能性がある。また、先行研究が指摘するように([?]), RNNモデルは、特に白樺の識別においてSVMモデルを上回った(SVMで0.781、RNNで0.831)。本研究では、単一日SVM、複数日SVM、複数日RNNの3つのピクセルベース分類法を検証し、複数日データとRNN分類器の組み合わせが最も良い性能を達成することを明らかにしました。しかし、このモデルはさらに改善することが可能です。16]が主張するように、パッチベースの分類法が性能を向上させる可能性があります。このようなパッチベースのモデルは、小さなパッチの時系列を入力とし、テクスチャなどの空間情報を分類処理に利用するものである。

4.2 ジオレフィケーション手法の性能とその限界。

地上画像を生態系モニタリングに利用する際の最大の障壁は、GISに対応した地理空間データとして扱うことが困難であることです。この問題を解決するために、自動的かつ正確な地理補正の方法が必要とされました。

の課題である。ジオレクティフィケーションを行わないと、取得した情報（本研究では植生分布）を定量的に解析（面積測定、場所の特定、地形データによる解析など）することができない。そこで、このような画像に対して、新しいジオレクティフィケーションの方法を提案しました。本手法は、最小限の手動入力（カメラの位置とカメラの初期パラメータ）により、最先端の精度（3.45m）を達成した。本手法の2つの特徴であるレンズ歪みモデルと画像マッチングによるGCPの自動取得の有効性を検証した。その結果、レンズディストーションモデルがジオレクティフィケーションの精度を大幅に向上させることが分かりました。しかし、レンズの歪みがジオレクティフィケーションの精度に与える影響は、カメラやレンズによって異なるため（[19]）、レンズ歪みモデルの優位性を確認するためには、さらなるテストが必要です。なお、提案するレンズ歪みモデルは、魚眼レンズや全方位カメラには適用できません。本手法のもう一つの特徴は、シミュレーション画像と画像マッチング技術によるGCPの自動取得である。この方法では、カメラの視野をカバーする高解像度のオルソフォトが必要である。その分コストもかかりますが、見返りは大きいです。この結果は、より広い範囲で画像とDSMのマッチング点を取得することが、カメラパラメータ推定に有効であることを示唆しています。しかし、提案手法（AKAZE image matcher）では、カメラに近い領域でマッチング点を取得できず、投影誤差が比較的大きくなっています（8）。模擬画像の空間分解能はオルソフォトの分解能に依存し、固定（本研究では1m）であるのに対し、元画像の分解能はカメラからの距離によって変化する。このような近距離では、元画像の解像度はシミュレーション画像の解像度よりもはるかに高く、画像マッチャーはその差を処理することができません。近年、画像ソースや視点の違いに頑健な、ディープラーニングを用いた画像マッチング手法（例えば[25]、[26]）が研究者によって開発されています。これらの手法をGCP取得処理に適用することで、特に近傍領域において本手法の性能を向上させることができるかもしれません。

4.3 今後の応用と結論

ここでは、デジタルタイムラプスカメラで撮影された一連の画像から植生図を自動作成する手法を提案した。作成された植生図は、固有種や脆弱な高山植生をモニタリングするのに十分な精度を有している。デジタルタイムラプスカメラの利点の1つは、長期間の運用が可能なことである。既存の長期繰り返し撮影データに本手法を適用することで、植生変化とその傾向を定量的に把握することができるようになる。このような情報は、現地での観測や保全活動をより効果的に計画するために役立つ。本手法は、高山植生のモニタリングや、気候変動が高山生態系に与える影響の理解を、低コストで容易にするものである。

参考文献

- [1] 気候変動に関する政府間パネル（IPCC）. 気候変動2007: 物理的科学の基礎. IPCCの第4次評価報告書に対する第1作業部会の貢献 "Contribution of Working Group I to the Fourth Assessment Report of the IPCC". ケンブリッジ大学出版局, 2007.
- [2] Jake M. Alexander, Jonas J. Lembrechts, Lohengrin A. Cavieres, Curtis Daehler, Sylvia Haider, Christoph Kueffer, Gang Liu, Keith McDougall, Ann Milbau, Aníbal Pauchard, Lisa J. Rew, and Tim Seipel. 「山と高山生態系への植物の侵入：現状と今後の課題」（英語）。山地と高山生態系への植物の侵入：現状と将来の課題. *Alpine Botany*, 126:89-103, 10 2016.
- [3] 工藤学・天谷幸弘・星野武穂・金子昌美. 北日本の高山雪原におけるヒメシャラの侵入：拡大パターンと種多様性への影響. *生態と進化*, 1:85-96, 9 2011.
- [4] 天海祐弘・金子昌美・工藤学. 気候変動に対する高山性ヒメコマツのシュート成長と分布の生息地特異的応答. *Ecological Research*, 30:969-977, 11 2015.
- [5] 工藤学・木村光博・笠木哲也・河合由佳・平尾彰. 気候改善に対する高山植物の生息地特異的応答: フェルフィールドと雪原群落の比較. *Arctic, Antarctic, and Alpine Research*, 42:438-448, 11 2010.
- [6] Susana Baena, Justin Moat, Oliver Whaley, and Doreen S. Boyd. 上空からの種の同定. Uavs and the very high resolution challenge for plant conservation (植物保護におけるUAVsと超高解像度への挑戦). *PLOS ONE*, 12:e0188714, 11 2017.

- [7] Andrew D. Richardson, Bobby H. Braswell, David Y. Hollinger, Julian P. Jenkins, and Scott V. Ollinger. キャノピーフェノロジーの空間的・時間的変動の地表付近のリモートセンシング。 *Ecological Applications*, 19:1417-1428, 9 2009.
- [8] Dawn M. Browning, Jason W. Karl, David Morin, Andrew D. Richardson, and Craig E. Tweedie. Phenocams bridge the gap between field and satellite observations in an arid grassland ecosystem (乾燥草原生態系におけるフェノカムによる現地観測と衛星観測の橋渡し)。 *リモートセンシング* 2017, 9 巻, 1071 ページ, 9:1071, 10 2017.
- [9] 井手礼子, 小熊裕之. デジタルタイムラプスカメラを用いた高山生態系における融雪と植生フェノロジーの時間的・空間的変動検出のための費用対効果の高いモニタリング手法。 *Ecological Informatics*, 16:25-34, 7 2013.
- [10] D.M. Woebbecke, G. E. Meyer, K. Von Bargen, and D. A. Mortensen. 様々な土壌、残留物、照明条件下での雑草識別のためのカラーインデックス。 *ASAE 論文集*, 38:259-269, 1 1995.
- [11] Pablo F Alcantarilla, Jesús Nuevo, and Adrien Bartoli. 非線形スケール空間における加速特徴のための高速な明示的拡散。 *英国マシンビジョン会議論文集*, 2013.
- [12] Jan Tigges, Tobia Lakes, and Patrick Hostert. 都市部の植生分類。多時刻ラピッドアイ衛星データの利点。 *リモートセンシングオブエンバイロメント*, 136:66-75, 9 2013.
- [13] Nguyen Thanh Son, Chi Farn Chen, Cheng Ru Chen, Huynh Ngoc Duc, and Ly Yu Chang. A phenology-based classification of time-series modis data for rice crop monitoring in mekong delta, vietnam. *リモートセンシング* 2014, Vol.6, ページ135-156, 12 2013.
- [14] Katharina Heupel, Daniel Spengler, and Sibylle Itzerott. 多時期のリモートセンシングデータとフェノロジー情報を用いた進歩的な作物タイプ分類。 *PFG - Journal of Photogrammetry, Remote Sensing and Geoinformation Science*, 86:53-69, 4 2018.
- [15] Giorgos Mountrakis, Jungho Im, and Caesar Ogole. リモートセンシングにおけるサポートベクターマシン。 A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 66:247-259, 5 2011.
- [16] Atharva Sharma, Xiuwen Liu, and Xiaojun Yang. パッチベースのリカレントニューラルネットワークを使用した多時間のマルチスペクトルリモートセンシング画像からの土地被覆分類。 *ニューラル・ネットワーク*, 105:346-355, 9 2018.
- [17] Sepp Hochreiter, Jürgen Schmidhuber. 長期短期記憶。 *Neural Computation*, 9:1735-1780, 11 1997.
- [18] A.Messerli and A. Grinsted. 画像地理補正および特徴追跡ツールボックス。 *Imgrapt.Geoscientific Instrumentation, Methods and Data Systems*, 4:23-34, 2 2015.
- [19] Celine Portenier, Fabia Hüsler, Stefan Härer, and Stefan Wunderle. ウェブカメラを用いた積雪モニタリングネットワークに向けて。方法論と評価。 *Cryosphere*, 14:1409-1423, 4 2020.
- [20] Juyang Weng, Paul Cohen, and Marc Herniou. I i e e t r p o n s の歪みモデルによるカメラキャリブレーションと精度評価。 *iee e transactions on pattern analysis and machine intelligence*, 14, 1992.
- [21] ニコラウス・ハンセン、シビルレ・D・ミュラー、ペトロス・クーモウタコス。 共分散行列適応を用いたランダム化進化戦略の時間複雑性の低減(cma-es)。 *進化計算*, 11:1-18, 3 2003.
- [22] Rコアチーム。 R: A language and environment for statistical computing, 2022.
- [23] Edzer Pebesma. 星。 時空間アレイ、ラスタおよびベクトルデータキューブ、2022年。 <https://r-spatial.github.io/stars/>, <https://github.com/r-spatial/stars/>.
- [24] Robert J Hijmans. terra: Spatial data analysis, 2022. <https://r-spatial.org/terra/>.
- [25] Zhuoqian Yang, Tingting Dan, and Yang Yang. 深い畳み込み特徴を用いた多時間のリモートセンシング画像登録。 *IEEE Access*, 6:38544-38555, 7 2018.
- [26] Guorong Wu, Minjeong Kim, Qian Wang, Yaozong Gao, Shu Liao, and Dinggang Shen. MR脳画像の変形可能な登録のための教師なし深層特徴学習。 医用画像 コンピューティングとコンピュータ支援インターベンション: MICCAI ... 医用画像 コンピューティングとコンピュータ支援インターベンションに関する国際会議, 16:649, 2013.