

高山生態系におけるデジタルタイムラプスカメラを用いた植生図の自動作成

プレプリント

岡本 亮太郎 *.
筑波大学大学院生物学研究
科博士後期課程

305-8577 茨城県つくば市天王台1丁目1番1号
okamoto.ryotaro.su@alumni.tsukuba.ac.jp

小熊裕之
生物多様性部門

国立環境研究所 〒305-8506 茨城県つくば市小
野川16-2

oguma@nies.go.jp

井手礼子
地球システム部門

国立環境研究所 〒305-8506 茨城県つくば市小
野川16-2

ide.reiko@nies.go.jp

2022年5月24日

概要

ここにアブストラクトのテキストを入力してください。

Keywords 高山生態学 - 深層学習 - 生態系モニタリング

1 はじめに

気候変動が陸域生態系に及ぼす影響は、特に高山地帯で顕著です([1])。高山植生は、低温や長い積雪期間といった厳しい条件に依存している。そのため、高山地帯には、極限環境に適応した希少種や固有種が生息している。近年の地球規模の気候変動（気温の上昇や積雪期間の短縮など）が、高山域への外来種の侵入を加速させていることが、いくつかの研究で報告されています([2]参照)。日本では、無雪期の延長を背景に、ヒメシャラ (*Sasa kurilensis*) が高山の雪原に侵入している([3])。また、気候変動は在来種の生育やフェノロジーに影響を与えている。例えば、日本の高山地帯で優占種であるハイマツの成長は、気温や融雪量などの気候条件の影響を受けている([4])。このような変化をモニタリングし、予測することは、効果的な保全計画を立てるために必要不可欠である。気候変動が高山植生に与える影響は、種やマイクロハビタットによって異なるため([5])、空間的に高解像度で広い範囲のモニタリングが必要である。

これまでの研究は、主に現地での観測に頼ってきたが、高山地帯は交通の便が悪く、天候も厳しいため、広範囲をカバーすることは難しい。衛星、航空機、無人航空機(UAV)によるリモートセンシングがその代替手段と思われる。しかし、衛星画像は雲に覆われているため、高山域の画像はほとんど得られず、空間分解能も植物群落のスケールで植生変化を観察するには十分ではありません。航空機による画像は高解像度のデータを得ることができるが、頻繁にモニタリングを行うにはコストがネックとなる。UAVによる手法は生態系モニタリングのための費用対効果の高いツールとなっていますが([6])、高山地域でのUAVの運用は強風と厳しい地形により困難です。

一方、森林([7])、草原([8])、高山草原([9])などでは、地上に設置した自動デジタルタイムラプスカメラによる緑葉のフェノロジーモニタリングも行われています。衛星画像とは異なり、雲や大気の影響を受けずに撮影することができます。また

*<https://github.com/0kam>

は、高解像度（すなわち、サブメータースケール）かつ高頻度（すなわち、毎日または毎時）の画像をわずかなコストで取得することができる。これらの研究では、画像中にいくつかの関心領域（ROI）を設定し、フェノロジー指標（例えば、過剰緑度、[10]）を算出しています。また、このようなタイムラプス画像から植生分布やその変化を視覚的に解釈することも可能である。しかし、これに取り組んだ研究はほとんどない。これは、このようなタイムラプス画像を植生分布のモニタリングに適用するには、2つの技術的な課題があるためと思われる。

第一に、衛星のマルチスペクトルセンサーと異なり、通常のデジタルカメラは3つのバンド（赤、緑、青）しか取得できないため、植生を分類することが困難である。第二に、デジタルタイムラプスカメラは地上に設置されるため、これらの画像を地理空間データ（オルソ画像など）に変換することが困難であることです。つまり、植生変化を発見しても、その地理的位置を特定できず、他の地理データ（地形など）と合わせて解析することができない。地上のタイムラプス画像を地理データとして扱うことは、保全計画に活用するために必要不可欠です。

本研究では、この2つの課題を解決することで、デジタルタイムラプスカメラによる植生図の自動描画と植生変化の位置特定を行う手法を提案する。第一の課題に対しては、葉色の時間変化を植生分類に利用することで解決した。また、第二の課題に対しては、地上写真を正確に地理データに変換する方法を開発した。最後に、本手法の応用例として、日本アルプスの8年間のデジタルタイムラプス画像を用いて、植生変化の検出と局所化を行った例を紹介する。我々は、安価で高性能なデジタルタイムラプスカメラを高山生態系の保全に利用することを目指している。

2 材料と方法

2.1 デジタルタイムラプスカメラ画像

国立環境研究所が所有する繰り返し撮影データを使用しました。すべての画像は国立環境研究所のウェブページ (<https://db.cger.nies.go.jp/gem/ja/mountain/station.html?id=2>) で公開されている。国立環境研究所は2010年、北アルプスの立山（標高3015m）の麓にある山小屋・室堂山荘（標高約2350m、森林限界より高い）にデジタルタイムラプスカメラ（EOS 5D MK2, Canon Inc.、21Mピクセル）を導入した。撮影は、午前6時から午後7時まで、1時間に1枚。撮影範囲は、標高約2350mから3015mまでの立山を含む。この地域は、岩石、崖、カル、モレーンなどの地形のため、モザイク状の複雑な植生構造になっています。4月から11月にかけて、常緑樹、落葉矮小樹（*Pinus pumila*, *Sorbus sp.*など）、矮小竹（*Sasa kurilensis*など）、高山草本（*Geum pentapetalum*, *Nephrophyllidium crista-galli*など）の雪解けと季節のフェノロジーがカメラによって観察されてきた。2012年および2020年の晩夏から晩秋にかけての画像を使用した。

2.2 前処理

2.2.1 画像を選択する

まず、植生分類に適した画像を選定した。毎年、晩夏から晩秋にかけての天候の良い4日間（2010年は9/19、10/1、10/11、10/23、2020年は9/19、10/2、10/11、10/23）を選びます。この時期の画像は、植生と紅葉の色づきのパターンを分離できるため、この時期の画像を使用しました。また、影などの時間的ノイズの影響を避けるため、各日午前11時から午後2時までの4枚の画像を選びました。最終的に、各年で16枚の画像を得ることができました。

2.2.2 画像間の自動アライメント

風の影響で画像同士が若干ずれているため、処理前に位置合わせを行った。プログラミング言語Python3と画像処理ライブラリOpenCV4 (<https://opencv.org/>) を用いてプログラムを実装しました。まず、2010年の画像1枚をアライメント対象として設定しました。次に、AKAZE 局所特徴抽出器 ([11]) と K-nearest neighbor matcher を用いて、対象画像と他の画像との間で一致するキーポイントを自動検出した。そして、OpenCVの "findHomography" 関数を用いて、マッチング点の各ペア間の距離を最小化するホモグラフィ行列を探索し、適用した。

2.3 自動植生分類

次に、繰り返し撮影画像の画素時系列を植生に分類しました。落葉植物は、秋のフェノロジーが種によって大きく異なるため、研究者はその情報を使って

衛星画像を用いた植生分類（例: [12], [13], [14]）。今回の対象地域では、秋のピクセル時系列を利用して、植生タイプを認識することができます（図2）。しかし、地上波繰り返し撮影画像に本手法を適用した研究はありません。そこで、高解像度かつ高頻度の繰り返し撮影データを活用するために、ディープラーニングによる分類手法を開発しました。図3はその分類の様子を示しています。

2.3.1 モデル・アーキテクチャ

地上の写真は高い空間分解能（我々のデータセットではサブメートルスケール）を提供できるため、葉の質感を分類のための追加情報として利用することができます。例えば、ヒメシャラでは光沢のある表面、ヒメシャラではマットな表面を見ることができます。そこで、1画素ではなく、小さなパッチ（9×9画素四方）をモデルの入力とした。したがって、モデルの入力は画像パッチの時系列となる。

本モデルでは、このデータ構造を扱うために、2つのコンポーネントを用意しています（図3参照）。まず、CNN（Convolutional Neural Network）層を用いて、各パッチの特徴（テクスチャなど）を抽出する（図4a）。CNNは、画像などのデータの空間構造を認識することに特化したニューラルネットワークである。CNN部は、抽出した特徴を時系列で出力する。次に、RNN（Recurrent Neural Net）層（図4b）を用いて、CNN部で抽出された特徴の時間パターンを分類する。RNNは、テキストや音声などの時間的・連続的なデータのダイナミクスを認識することに特化したニューラルネットワークである。RNNには様々な種類があるが、我々はLong Short Time Memory（LSTM、[15]）を用いた。CNNとRNNを組み合わせることで、入力画像パッチ時系列を、各パッチの色や質感、時間パターンを考慮して分類することができる。このCNN-RNNアーキテクチャは、音声分類([16])やシーンテキスト認識([16])にも利用されている。

ディープラーニングの手法を使うことで、もう一つ良い副次的効果があります。高解像度画像（16×21M pix）を使用するため、学習データセットが膨大になり、一度にモデルに与えることができなくなります：コンピュータのRAMを大量に消費してしまいます。しかし、ディープラーニングの手法を用いれば、ミニバッチと呼ばれる小分けにして提供することで、RAMの消費を抑えることができるのです。

2.3.2 データセットの準備

植生クラスは、ハイマツ、ハイマツ竹、その他の植生、植生なし、空の5種類を設定した。フリーの画像アノテーションソフト（Semantic Segmentation Editor, Hitachi, <https://github.com/Hitachi-Automotive-And-Industry-Lab/semantic-segmentation-editor>）を用いて、専門家が2015年の画像に各クラスごとにポリゴンを描画した。2012年、2015年、2020年では植生が異なる可能性があるため、この教師データを2012年と2020年の画像に適用すると、誤分類が発生する可能性がある。しかし、植生の変化は、植物群落の端で起こることが予想される。そこで、各ポリゴンを数ピクセルずつ縮小して学習に適用しています。

2.3.3 実装とモデルトレーニング

Python3言語とPyTorchディープニューラルネットワークライブラリを用いて分類器を実装しました（<https://pytorch.org/>）。すべてのソースコードはGitHub（<https://github.com/0kam/xxxx>）で公開されています。

3 自動ジオレクティフィケーション

そこで、地上の風景画像をGISで利用可能な地理データに変換する新しい方法を開発しました。これはジオレクティフィケーションと呼ばれる処理です。これまで、地上画像のジオレクティフィケーションは困難な作業であり、そのために地上画像に潜在する豊富な情報が十分に活用されていとは言えませんでした。ジオレクティフィケーションとは、画像をデジタルサーフェスモデル（DSM）に変換し、画像の各ピクセルに地理的な座標を付与することを意味します。カメラは、3次元の地理座標（緯度、経度、高度）を2次元の画像座標（各画素の位置）に変換する関数と考えることができます。そこで、この関数のパラメータ（カメラの位置、姿勢、視野など）を推定することで、画像をDSMに写すことができます。この処理については、数学的にわかりやすく説明されているので、読者の方には[17]をお勧めします。通常、ジオレクティフィケーションは3つのステップを経て行われます。

1. 画像内のGCP（Ground Control Point）を検索する。
2. GCPを用いたカメラのポーズや視野などのカメラパラメータの推定。
3. カメラパラメータを用いてDSM上に画像をマッピングする。

近年、氷河研究 ([18]) や積雪研究 ([17]) において、地上写真を利用したジオレクティフィケーションの手法が開発されている。特に、[17] は山のシルエットを GCP とした半自動的な手法であり、特筆に価するものである。しかし、このシルエットを用いた方法は、投影精度に欠点がある。また、レンズの歪みを無視している。今回の対象地は植生分布が複雑で、カメラのレンズの歪みも大きいため、より精度の高い方法が必要でした。

3.1 ローカルフィーチャーに基づく画像とDSMのマッチング

より広域の画像とDSMのマッチング点を得るために、既にジオレクチュアを行った航空機画像を使用しました。そして、航空機から撮影した画像とDSMを組み合わせて、模擬的な地形画像を作成しました (図x)。そして、ターゲット画像とこのシミュレーション画像にAKAZEの局所特徴量マッチャーを適用し、マッピングポイント (GCP) を取得しました (図x)。GCPは、地理座標 (DSMから) と画像座標 (画像から) を持っています。この手順では、シミュレーション画像をレンダリングするために、カメラの正確な位置とカメラの初期パラメータが必要です。

3.2 レンズの歪みのモデリングと推定

レンズの歪み (1) は、[19]とOpenCVの実装に基づきモデル化した。このモデルには、半径方向 ($k_1 k_6$)、接線方向 (p_1, p_2)、薄いプリズム ($s_1 s_4$)、および画素の縦横比 (a_1, a_2) の歪みが含まれています。レンズ歪みのモデリングの詳細については、Wengら (1992) を参照してください。このように、レンズの歪みパラメータとその他のカメラパラメータ (カメラの位置、姿勢、視野) を用いて、GCPの地理座標を画像座標に投影することができるようになりました。これら (カメラ位置を除く) は、共分散行列適応進化法 (CMA-ES, [20]) を用い、GCPの二乗投影誤差を最小にすることで最適化しました。カメラ位置は問題が複雑になるため、推定できなかった (例えば、遠くから撮影した望遠と近くから撮影した広角は似ている)。

$$\begin{aligned} \begin{pmatrix} x' \\ y' \end{pmatrix} &= \begin{pmatrix} r \\ y' \end{pmatrix} \frac{1 + k_1 r^2 + k_2 r^4 + k_3 r^6}{1 + a_1 k_1 r^2 + k_2 r^4 + k_3 r^6} + \begin{pmatrix} p_1 x' y' + p_2 (r^2 + 2y'^2) + p_3 x' y' + s_1 r^2 + s_4 r^4 \\ 2p_1 x y + p_2 (r + 2x) + s_1 r + s_4 r \end{pmatrix} \end{aligned} \quad (1)$$

3.3 実装とデータセット

このアルゴリズムをPython3で実装し、オープンソースのパッケージとしてGitHub (<https://github.com/0kam/alproj>) で公開しました。手持ちのデータで試すことができる。また、DSMとして国土地理院が提供する5m解像度のデジタル標高モデルを使用した。

4 結果

4.1 植生分類精度

植生分類器の性能は、5重のクロスバリデーションにより評価した。それぞれのフォールドは植生カテゴリで層別された。ここで、 TP , FP , FN はそれぞれ、真陽性、偽陽性、偽陰性を表す。

$$\text{精度} = \frac{TP}{TP + FP} \quad (2)$$

$$\text{リコール} = \frac{TP}{TP + FN} \quad (3)$$

$$F1 = \frac{2 \cdot \text{精度} \cdot \text{リコール}}{\text{精度} + \text{リコール}} \quad (4)$$

$$\text{ionrecall} \quad (5)$$

植生分類器は、5つのカテゴリすべてにおいて高い再現性と精度を達成した。2.学習データが最も少ない矮小竹では、リコールと精度が最も低くなった。矮小竹でも偽陽性が発生した。

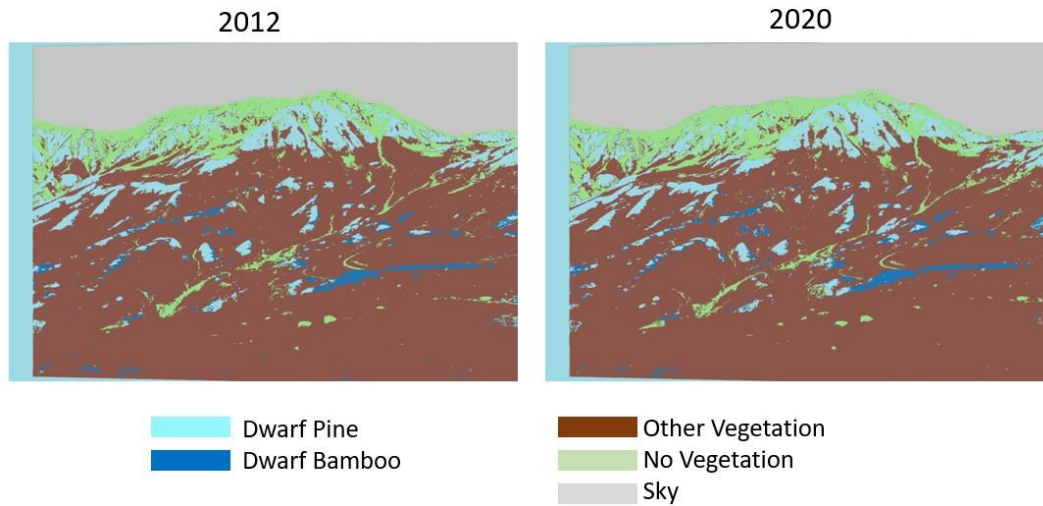


図1：植生分類結果

が低頻度（約5%）で発生し、パイプラインが見逃した真陽性はごくわずか（約4%）であった。各メトリクスの加重平均が高い（0.99以上）ため、トレーニングデータセットを植生カテゴリでバランスさせると、これらの結果が改善される可能性があります。

は植生分類の成果物である。植物群落のスケールでハイマツやハイマツタケの分布を観察することができる。

	マクロ平均、N = 5	**加重平均**、N = 5	**ドワーフパイン**、N = 5	**ドワーフ・バンブー** (Dwarf Bamboo)
高精度	0.977 (0.008)	0.997 (0.001)	0.977 (0.012)	0.951 (0.013)
リコール	0.987 (0.001)	0.997 (0.001)	0.995 (0.003)	0.960 (0.006)
F1 スコア	0.982 (0.005)	0.997 (0.001)	0.986 (0.005)	0.955 (0.004)

4.2 ジオレクティフィケーション精度

4.3 植生図

4.4 植生変化の検出と局在化

5 ディスカッション

我々は、タイムラプス画像をわずかなコストでジオリファレンス付き植生マップに変換する完全自動化手順を提案した。この課題は、1.デジタルカメラで撮影された順次画像から植生进行分类することの難しさ、2.ジオレクティフィケーションの難しさ、に起因しています。我々は、1.紅葉の時間情報を植生分類に利用すること、2.高精度なジオレクティフィケーションのための新しい手法を開発することによって、これらの課題を解決しました。植生分類の性能（精度0.87）、地理補正の方法（RMSE *rmse* m）は実用的である。

5.1 植生分類に時系列画像を使用することの利点

デジタルカメラの欠点は、赤・青・緑の3バンドしかないことです。この情報不足を補うために、タイムラプスカメラが持つ豊富な時間情報を利用しました。多くの植物には、開花や紅葉など、特徴的なフェノロジーがあります。観察する

の場合、長期的（通年など）かつ高頻度のモニタリングが必要であり、デジタルタイムラプスカメラが適している。本研究では、1枚の画像でも分類が容易な2種（ハイマツとストーンパイン）のみを対象とした。しかし、先行研究（[12]、[13]、[14]）と同様に、本手法でも葉色の時間情報を利用してより多くの植生（例えば、矮性落葉樹や高山性の草本植物）を分類できると期待されます。また、各日の1時間ごとの画像を使用しました。図xは、この追加情報により、影などの過渡的なノイズに対して我々のモデルが頑健になったことを示しています。高山の生態系は地形が粗いため、影は大きな問題である。この点でも、タイムラプスカメラは有効である。

5.2 ジオレフィケーション手法の性能とその限界。

5.3 今後の応用と結論

参考文献

- [1] 気候変動に関する政府間パネル（IPCC）. *気候変動2007:物理的科学の基礎:IPCCの第4次評価報告書に対する第1作業部会の貢献 "Contribution of Working Group I to the Fourth Assessment Report of the IPCC*. ケンブリッジ大学出版局, 2007.
- [2] Jake M. Alexander, Jonas J. Lembrechts, Lohengrin A. Cavieres, Curtis Daehler, Sylvia Haider, Christoph Kueffer, Gang Liu, Keith McDougall, Ann Milbau, Aníbal Pauchard, Lisa J. Rew, and Tim Seipel. 「山岳地帯と高山生態系への植物の侵入：現状と今後の課題」。山地と高山生態系への植物の侵入：現状と将来の課題。 *Alpine Botany*, 126:89-103, 10 2016.
- [3] 工藤学・天谷幸弘・星野武穂・金子昌美. 北日本の高山雪原におけるヒメシャラの侵入：拡大パターンと種多様性への影響. *生態と進化*, 1:85-96, 9 2011.
- [4] 天海祐弘・金子昌美・工藤学. 気候変動に対する高山性ヒメコマツのシュート成長と分布の生息地特異的応答. *Ecological Research*, 30:969-977, 11 2015.
- [5] 工藤学・木村光博・笠木哲也・河合由佳・平尾彰. 気候改善に対する高山植物の生息地特異的応答: フエルフィールドと雪原群落の比較. *Arctic, Antarctic, and Alpine Research*, 42:438-448, 11 2010.
- [6] Susana Baena, Justin Moat, Oliver Whaley, and Doreen S. Boyd. 上空からの種の同定。Uavs and the very high resolution challenge for plant conservation（植物保護におけるUAVsと超高解像度への挑戦）。 *PLOS ONE*, 12:e0188714, 11 2017.
- [7] Andrew D. Richardson, Bobby H. Braswell, David Y. Hollinger, Julian P. Jenkins, and Scott V. Ollinger. キャノピーフェノロジーの空間的・時間的変動の地表付近のリモートセンシング. *Ecological Applications*, 19:1417-1428, 9 2009.
- [8] Dawn M. Browning, Jason W. Karl, David Morin, Andrew D. Richardson, and Craig E. Tweedie. フェノカムは、乾燥草地生態系におけるフィールドと衛星観測のギャップを埋める。 *リモートセンシング* 2017、9巻、1071ページ、9:1071、10 2017.
- [9] 井手礼子, 小熊裕之. デジタルタイムラプスカメラを用いた高山生態系における融雪と植生フェノロジーの時間的・空間的変動検出のための費用対効果の高いモニタリング手法. *Ecological Informatics*, 16:25-34, 7 2013.
- [10] D.M. Woebbecke, G. E. Meyer, K. Von Bargen, and D. A. Mortensen. 様々な土壌、残留物、照明条件下での雑草識別のためのカラーインデックス. *ASAE 論文集*, 38:259-269, 1 1995.
- [11] Pablo F Alcantarilla, Jesús Nuevo, and Adrien Bartoli. 非線形スケール空間における加速特徴量のための高速な明示的拡散. *英国マシンビジョン会議論文集*, 2013.
- [12] Jan Tigges, Tobia Lakes, and Patrick Hostert. 都市部の植生分類。多時刻ラピッドアイ衛星データの利点。 *リモートセンシングオブエンバイロメント*, 136:66-75, 9 2013.
- [13] Nguyen Thanh Son, Chi Farn Chen, Cheng Ru Chen, Huynh Ngoc Duc, and Ly Yu Chang. A phenology-based classification of time-series modis data for rice crop monitoring in mekong delta, vietnam. (ベトナムのメコンデルタにおける稲作モニタリングのための時系列モディスデータのフェノロジーに基づく分類) . *リモートセンシング* 2014, Vol.6, ページ135-156, 12 2013.
- [14] Katharina Heupel, Daniel Spengler, and Sibylle Itzerott. 多時期のリモートセンシングデータとフェノロジー情報を用いた進歩的な作物タイプ分類. *PFG - Journal of Photogrammetry, Remote Sensing and Geoinformation Science*, 86:53-69, 4 2018.

- [15] Sepp Hochreiter, Jürgen Schmidhuber. 長期短期記憶. *Neural Computation*, 9:1735-1780, 11 1997.
- [16] 邵博光、白翔、姚瑋. 画像ベースのシーケンス認識のためのエンドツーエンドの訓練可能なニューラルネットワークとそのシーンテキスト認識への応用. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39:2298-2304, 7 2015.
- [17] Celine Portenier, Fabia Hüsler, Stefan Härer, and Stefan Wunderle. ウェブカメラを用いた積雪モニタリングネットワークに向けて. 方法論と評価. *Cryosphere*, 14:1409-1423, 4 2020.
- [18] A.Messerli and A. Grinsted. 画像地理補正および特徴追跡ツールボックス. *Imgrapt.Geoscientific Instrumentation, Methods and Data Systems*, 4:23-34, 2 2015.
- [19] Juyang Weng, Paul Cohen, and Marc Herniou. *I i e e t r p o n s* の歪みモデルと精度評価によるカメラのキャリブレーション. *ieee transactions on pattern analysis and machine intelligence*, 14, 1992.
- [20] ニコラウス・ハンセン、シビルレ・D・ミュラー、ペトロス・クーモウタコス. 共分散行列適応を用いたランダム化進化戦略の時間複雑性の低減(cma-es). *進化計算*, 11:1-18, 3 2003.